# Da cópia à divergência

## Reutilização, propagação e evolução de Agent Skills no GitHub

Proposta de estudo empírico com desenho quantitativo e qualitativo

**Tópicos em Engenharia de Sistemas de Software II**
**Discente: Jemison dos Santos**
**Professor: Dr. Igor Wiese**



PROBLEMA

# A reutilização ocorre sem infraestrutura de atualização

Agent Skills são instruções em linguagem natural carregadas probabilisticamente por agentes. Elas podem incluir scripts e referências, mas não possuem registro ou gerenciador de pacotes central.

**50,5%**

das ocorrências coletadas são cópias verbatim

Questão central

**O que acontece quando um artefato operacional se espalha por copy-and-paste, sem mecanismo formal para propagar correções, atualizações ou revisões?**

Fontes: [1], [8]

# Code clones não explicam a evolução de Agent Skills

| Trabalho | Contribuição relevante | Papel nesta pesquisa |
|---|---|---|
| GitSkills (2026) | Dataset e questões abertas | População, esquema e lacuna |
| Destefanis (2026) | Skills como artefatos de software | Métricas textuais e estruturais |
| Kim et al. (2005) | Genealogias de clones | Modelo longitudinal |
| Krinke (2007) | Mudanças consistentes/inconsistentes | Padrões de propagação |
| Bettenburg et al. (2012) | Inconsistência não implica defeito | Interpretação cautelosa |
| Thummalapenta et al. (2010) | Manutenção de clones | Indicadores evolutivos |
| Sousa et al. (2026) | Clones em desenvolvimento humano–IA | Ponte com agentes |

Fontes: [1]–[7]

# A lacuna está na propagação de instruções para agentes

## Já sabemos

Como clones de código formam genealogias e recebem mudanças consistentes ou divergentes.

## Ainda não sabemos

Quais skills se propagam, como evoluem depois da cópia e quando a divergência altera comportamentos relevantes.

## Contribuição proposta

Um modelo empírico que conecta características → reutilização → evolução → divergência.

**Diferencial: tratar a skill como artefato de software natural-language-first, selecionado probabilisticamente e distribuído por cópia.**

Fontes: [1]–[5]

OBJETIVO

# O objetivo conecta reutilização, evolução e confiança

**Investigar empiricamente os fatores associados à reutilização de Agent Skills e caracterizar como skills reutilizadas se propagam e divergem entre repositórios.**

**Características**

textuais, estruturais e contextuais

**Propagação**

alcance e concentração do reúso

**Evolução**

estabilidade e mudanças

**Divergência**

alterações comportamentais relevantes

A pesquisa busca associações; não atribui causalidade a partir de dados observacionais.

Fontes: Aula 02; [1], [2]

QUESTÕES DE PESQUISA

# Três questões constroem uma explicação cumulativa

**RQ1** **Como a reutilização está distribuída e quais características textuais, estruturais e contextuais estão associadas à ampla propagação?**

**RQ2** Quais padrões de estabilidade, divergência e propagação de alterações emergem após as skills serem copiadas entre repositórios?

**RQ3** Quais características estão associadas a mudanças que introduzem ou removem comandos, acesso externo ou artefatos executáveis?

Fontes: [1], [8]

# O método combina escala populacional e validação qualitativa

## FASE 1

### Caracterizar

Definir população, deduplicar conteúdos, medir reúso e extrair métricas.

## FASE 2

### Reconstruir

Amostrar famílias, recuperar históricos Git e montar genealogias de variantes.

## FASE 3

### Validar e explicar

Classificar mudanças, medir concordância e testar robustez estatística.

**Unidades: conteúdo distinto para RQ1; família/genealogia de cópias para RQ2–RQ3.**

Fontes: Aulas 01–03; [8]

# RQ1 separa adoção de intensidade de propagação

### Variável dependente

**Reuse(s) = número de repositórios distintos que contêm o conteúdo s**

### Métricas explicativas

Textuais: tamanho, descrição, legibilidade, URLs, code blocks
Estruturais: seções, listas, scripts, referências
Contextuais: estrelas, idade, atividade, linguagem, fork

## Hurdle model

| | |
|---|---|
| Modelo 1 | **P(reuse > 1)**<br>**Regressão logística** |
| Modelo 2 | **Contagem entre reutilizadas**<br>**Regressão binomial negativa** |

**Controles: popularidade, idade, atividade, linguagem, fork e idade da skill. Reportar efeito + IC 95%.**

Fontes: Aula 02; [1]

# RQ2–RQ3: genealogias e validação manual

01

### 1. Amostra

Famílias estratificadas por intensidade de reúso e contexto.

02

### 2. Histórico

Git completo via BYOD; primeira ocorrência observada ≠ origem comprovada.

03

### 3. Mudanças

Diffs classificados: descrição, instruções, comandos, rede, scripts e referências.

04

### 4. Validação

Dois avaliadores; Cohen κ; precisão, recall e F1 para automação.

**Saída: padrões de estabilidade, especialização, propagação consistente/inconsistente e mudanças comportamentalmente relevantes.**

Fontes: [3]–[5], [8]

DADOS UTILIZADOS

# GitSkills preserva ocorrências, contexto e história

| Componente | Registros | Conteúdo usado no estudo |
|---|---|---|
| artifacts | 3.797.117 | repositório, path, hash, texto, front matter, tamanho |
| repos | 282.200 | owner, estrelas, linguagem, fork, criação e último push |
| artifact_siblings | 7.264.865 | scripts, referências, arquivos e diretórios associados |
| histórico em artifacts | 458.548 | primeiro/último commit, autores anonimizados, commits |
| BYOD Git/GitHub | amostra RQ2–RQ3 | histórico completo e diffs para genealogias |

**Snapshot principal: julho de 2026 · SQLite (44 GB) · unidade RQ1: content_hash distinto**

Fontes: [1], [8]

# A coleta preservou cada ocorrência antes do enriquecimento

### 1. Discovery

Busca por SKILL.md em repositórios públicos. Intervalos de tamanho contornam o limite de 1.000 resultados da busca.

### 2. Deduplicação

Agrupamento por content_hash. Um representante determinístico por conteúdo; todas as cópias permanecem ligadas.

### 3. Enriquecimento

Texto, front matter, siblings, metadados do repositório e histórico amostrado do arquivo.

**Resultado: um censo observável de branches padrão — útil para população, mas ainda um limite inferior do ecossistema.**

Fontes: [1]

ANÁLISE INICIAL — ESCALA

# O dataset combina escala, diversidade e contexto evolutivo

**3.797.117**
ocorrências de SKILL.md

**1.877.981**
conteúdos distintos

**282.200**
repositórios públicos

**195.841**
proprietários

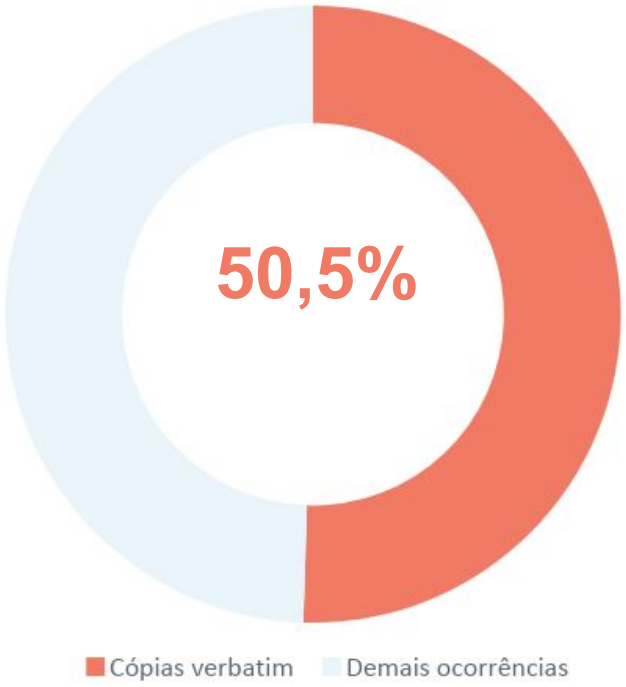
**7.264.865**
arquivos auxiliares

**458.548**
históricos amostrados

**Os 3,8 milhões de registros são ocorrências; a análise de reutilização deve distinguir cópia de conteúdo único.**

Fontes: [1]

# As médias sugerem uma distribuição de longa cauda




| | |
|---|---|
| **2,02** | ocorrências por conteúdo distinto |
| **13,46** | ocorrências por repositório |
| **1,44** | repositórios por proprietário |
| **3,87** | arquivos auxiliares por conteúdo distinto |
| **24,4%** | cobertura de histórico sobre conteúdos distintos* |

* O histórico é amostrado por localização/tamanho; não é uma amostra aleatória simples. Medianas e percentis dependem da execução sobre o SQLite completo.

Fontes: [1], [8]

# As principais ameaças já orientam o desenho do estudo

## Construção

Filename match pode incluir falsos positivos; content_hash mede identidade byte a byte, não ancestralidade.

**Critérios explícitos + inspeção manual**

## Interna

Popularidade, idade, forks e catálogos podem confundir associações; correlação não demonstra causalidade.

**Controles, diagnósticos e sensibilidade**

## Externa

A busca cobre repositórios públicos e branches padrão sob limites de indexação; resultados são um limite inferior.

**Replicação por estratos e transparência**

**Robustez: repetir modelos sem forks, catálogos, templates, repositórios gerados e outliers extremos.**

Fontes: Aula 03; [1]

# A proposta transforma cópia em uma história científica completa

**Características → propagação → evolução → divergência → implicações para manutenção e confiança**

## Referências centrais


[1] Destefanis et al. GitSkills: A Dataset of Agent Skills on GitHub. MSR 2027.

[2] Destefanis. Authoring Agent Skills: A Software-Engineering Approach. 2026.

[3] Kim et al. An Empirical Study of Code Clone Genealogies. ESEC/FSE 2005.

[4] Krinke. Consistent and Inconsistent Changes to Code Clones. WCRE 2007.

[5] Bettenburg et al. Inconsistent Changes to Code Clones at Release Level. SCP 2012.

[6] Thummalapenta et al. Maintenance of Source Code Clones. ESE 2010.

[7] Sousa et al. Clone Genealogies in Human–AI Collaborative Development. MSR 2026.

[8] MSR 2027 Mining Challenge — GitSkills.


**Contribuição esperada: evidência reproduzível e recomendações para autoria, distribuição e manutenção de Agent Skills.**